ECOLE NATIONALE DES PONTS ET CHAUSSEES

PROJET DE PREMIERE ANNEE 2026

Optimisation des flux énergétiques dans un Microgrid résidentiel

Océane CHIA ; Chahine MAZOUZI ; Thineesh PUVIKARAN ; Matéo RENOIR ; Linley SHAM-PRADERIO ; Clovis VIALARD
sous la direction de
Mohamed Saâd El Harrab
Data Science for Complex Systems, Co-Innovation Lab, ENPC

ABSTRACT : This paper addresses the challenge of energy flux optimization in a residential microgrid integrating photovoltaic production, battery storage, and a smart Energy Management System (EMS). Using the Ausgrid Solar Home dataset — half-hourly measurements from 300 Australian households over three years — we simulate and evaluate strategies to reduce grid dependency and maximize solar self-consumption. A greedy EMS algorithm achieves a 39.8 % reduction in annual grid imports for a reference household. Two machine learning models, LSTM and XGBoost, are trained and compared for load forecasting, with XGBoost reaching a mean absolute error of 0.118 kWh at the 30-minute horizon. The results confirm the complementarity of predictive modeling and deterministic control for residential energy optimization.

KEYWORDS : Microgrid, Energy Management System(EMS), Battery Storage, Photovoltaic, Duck Curve, LSTM, XGBoost, Self-Consumption, Ausgrid

1 Introduction

Dans un contexte climatique extrêmement préoccupant, de plus en plus de particuliers s'équipent de dispositifs de production renouvelable, notamment de panneaux photovoltaïques résidentiels. Cependant, on constate un décalage temporel évident entre la surproduction solaire locale en milieu de journée, qui sature le réseau de distribution, et la baisse de production en fin de journée coïncidant avec le pic de consommation domestique. Ce déphasage est à l'origine du phénomène critique communément appelé la « Duck Curve ». Sans régulation, la stabilité technique du réseau principal est menacée (tension et fréquence), les infrastructures se dégradent plus facilement et, surtout, les particuliers restent dépendants du réseau principal aux heures tarifaires les plus lourdes. Les rapports de l'Agence Internationale de l'Énergie soulignent particulièrement cette dynamique, avec une part des renouvelables dans la production mondiale d'électricité projetée à 43 % d'ici 2030 [1].

Cette problématique justifie la motivation suivante : comment concevoir et dimensionner un système de gestion intelligent de l'énergie (EMS) qui, en s'appuyant sur des modèles mathématiques prédictifs et un dispositif de stockage par batterie, maximise l'autoconsommation d'un microgrid résidentiel afin de minimiser l'impact économique pour l'utilisateur ainsi que sa dépendance au réseau électrique principal ?

Afin de répondre à ce problème, deux systèmes ont été conçus : une brique de *machine learning* dédiée à la prévision de la consommation et de la production d'énergie future, et une brique de contrôle (EMS) chargée de piloter intelligemment la charge et la décharge d'un système de stockage. Ces deux systèmes ont été développés séparément, sans couplage, afin de valider, tester et fiabiliser chaque brique indépendamment, évitant qu'une erreur du modèle de prévision ne fausse l'algorithme de contrôle de la batterie. Le pas de temps a été fixé à 30 minutes, et le foyer de référence retenu est le client 13 du dataset Ausgrid, identifié comme représentatif par Ratnam et al. [2]. Pour le pilotage de la batterie, nous avons opté pour un algorithme glouton, permettant la charge en cas de surplus solaire et la décharge lors d'un pic de consommation. Contrairement à des méthodes d'optimisation mathématique lourdes ou des algorithmes génétiques, cette logique de contrôle consomme très peu de puissance de calcul et peut facilement être embarquée dans un petit boîtier électronique résidentiel.

La Figure 1 présente l'architecture générale du système étudié, illustrant les flux d'énergie entre les sources de production, le réseau électrique, la batterie et le foyer, ainsi que le rôle central de l'EMS dans les décisions de routage.

2 Matériels et méthodes

2.1 Origine et structure des données

Le projet s'appuie sur le jeu de données public *Ausgrid Solar Home Electricity Data*, issu d'un réseau de distribution australien (Nouvelle-Galles du Sud). Ce dataset recense les mesures énergétiques demi-horaires de 300 foyers équipés de panneaux photovoltaïques sur une période de trois ans (juillet 2010 – juin 2013). La résolution temporelle de 30 minutes constitue un compromis pertinent : suffisamment fine pour capturer les dynamiques intra-journalières (pic solaire, pointe du soir), elle reste cohérente avec la fréquence standard de nombreux relevés de compteurs communicants et offre une corrélation adaptée pour la modélisation des cycles de charge et décharge de batterie.

Chaque enregistrement brut associe un identifiant client (`Customer`), une catégorie de consommation (`Consumption_Category`), une date, et 48 colonnes numériques correspondant aux demi-heures de la journée (de 00 :00 à 23 :30). Trois catégories sont distinguées :

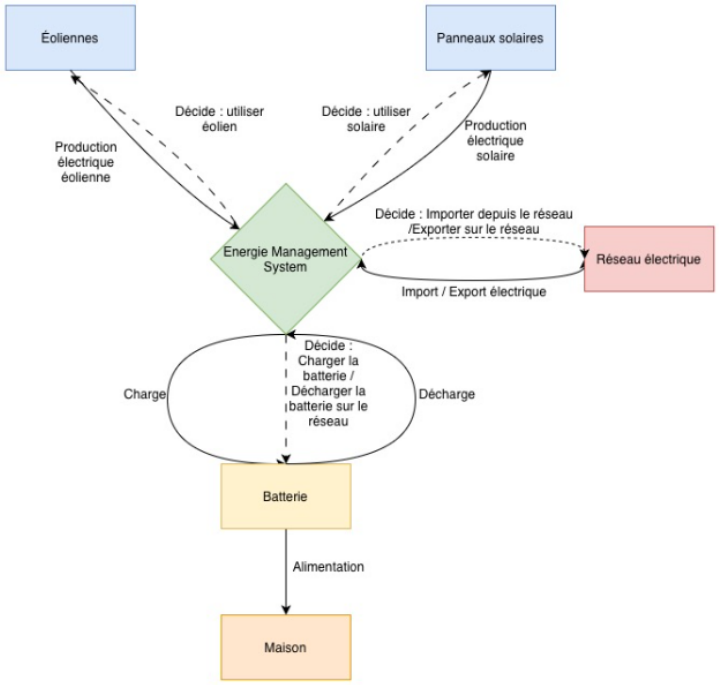


FIGURE 1 – *Architecture générale du microgrid résidentiel. L'EMS centralise les décisions de routage de l'énergie entre les sources de production (panneaux solaires, éoliennes), le réseau électrique, la batterie et le foyer. Les flèches pleines représentent les flux physiques d'énergie ; les flèches en pointillés représentent les décisions de l'EMS.*

— **GC** (*General Consumption*) : consommation générale du foyer,
— **CL** (*Controlled Load*) : charge pilotée, typiquement un chauffe-eau à accumulation,
— **GG** (*Generated and used/exported*) : production photovoltaïque brute.

L'étape de préparation consiste à passer de ce format *wide* (une ligne = un jour, 48 colonnes = les demi-heures) à un format *long* via la méthode `pandas.melt()`, qui génère une ligne par pas de temps et par catégorie. Un horodatage précis est ensuite reconstruit en combinant la date et le créneau horaire extrait du nom de colonne. Ce retraitement, appliqué aux fichiers 2011–2012 et 2012–2013 puis concaténés, constitue le socle de toutes les analyses ultérieures.

L'analyse initiale des 300 profils a révélé de nombreuses anomalies techniques : profils dits « vacances » avec consommation anormalement basse, défaillances d'onduleurs (production nulle en plein jour), ou erreurs de capteurs (production solaire enregistrée la nuit). Après filtrage, 54 clients ont été retenus. Le client 13 a été sélectionné pour l'ensemble des simulations, conformément aux recommandations de Ratnam et al. [2], qui identifient ce foyer comme représentatif d'un profil résidentiel avec production solaire significative et absence de valeurs aberrantes.

La variabilité saisonnière australienne (été en décembre–février, hiver en juin–août) influe directement sur le dimensionnement de la batterie : le surplus solaire, maximal en été, diminue fortement en hiver. L'analyse sur l'année 2012–2013 permet néanmoins de capturer ces deux régimes dans leur ensemble.

2.2 Construction du profil énergétique et analyse des flux

À partir du dataset transformé, deux séries temporelles sont isolées pour le client 13 :

$$\text{Load} = \text{GC} + \text{CL} \quad \text{(consommation totale du foyer)},$$
$$\text{PV} = \text{GG} \quad \text{(production photovoltaïque)}.$$

La charge nette (*Net Load*) est définie comme Load − PV. Lorsqu'elle est négative, le foyer produit un surplus non consommé immédiatement ; lorsqu'elle est positive, il doit importer depuis le réseau. On en déduit deux flux complémentaires :

— **Surplus** : $\max(0, -\text{Net Load})$ — énergie disponible pour le stockage ou l'injection réseau,

— **Grid Import** : $\max(0, \text{Net Load})$ — énergie effectivement soutirée du réseau.

L'autoconsommation instantanée est calculée comme PV − Surplus. Sur l'année 2012–2013, le bilan pour le client 13 révèle les grandeurs suivantes : consommation totale de 4 287 kWh, production solaire de 2 910 kWh, importation réseau de 3 323 kWh, et taux d'autoconsommation initial de 33,1 %. Plus de la moitié de l'énergie solaire est donc exportée sans valorisation locale — c'est précisément ce que l'ajout d'une batterie et d'un EMS vise à corriger.

La *Duck Curve*, visualisée sur la journée du 15 janvier 2013 (Figure 2), illustre clairement le décalage temporel entre la production solaire (pic à midi) et la consommation domestique (pointe en soirée), et justifie l'intérêt d'un système de stockage local.

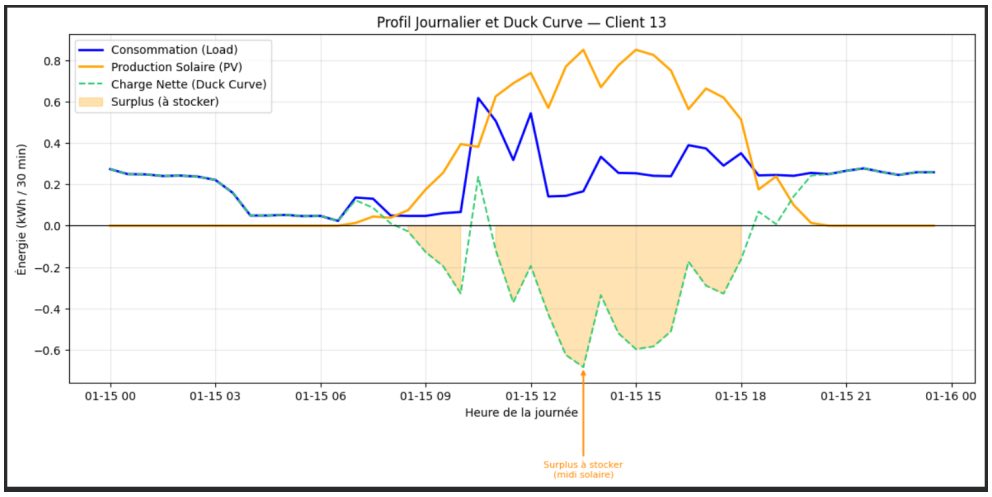


FIGURE 2 – *Duck Curve du client 13 — journée du 15 janvier 2013. La zone orange représente le surplus solaire non consommé en milieu de journée, disponible pour le stockage. La charge nette (courbe verte en pointillés) met en évidence le déphasage entre production et consommation.*

Le profil journalier moyen confirme cette asymétrie structurelle. La production solaire suit une cloche centrée autour de 12h30 heure locale, avec un pic moyen de l'ordre de 0,20 kWh par demi-heure en été australien (janvier). La consommation présente deux bosses caractéristiques : un premier plateau matinal (7h–9h) lié aux usages domestiques du début de journée, et une montée en soirée (17h–21h) correspondant au retour des occupants, au chauffage/climatisation et à la cuisson. La production excède la consommation pendant 4 à 6 heures par jour en été, générant un surplus qui, sans stockage, est injecté sur le réseau à un tarif de revente ($0{,}08$ €/kWh) très inférieur au tarif d'achat aux heures de pointe ($0{,}40$ €/kWh). Ce différentiel tarifaire de $0{,}32$ €/kWh constitue le levier économique principal de l'EMS.

2.3 Simulation de l'EMS avec stockage par batterie

Modèle de batterie. La batterie modélisée s'inspire des caractéristiques d'un système résidentiel de type Tesla Powerwall compact. L'état de charge (*State of Charge*, SOC) est suivi pas à pas et contraint entre $\text{SOC}_{\min}$ et $\text{SOC}_{\max}$ pour prévenir la dégradation accélérée des cellules électrochimiques. Les paramètres retenus sont présentés dans le Tableau 1.

Paramètre	Valeur
Capacité nominale	7 kWh
SOC minimal (protection décharge profonde)	$10\,\% \rightarrow 0{,}7$ kWh
SOC maximal (protection surcharge)	$90\,\% \rightarrow 6{,}3$ kWh
Rendement de charge/décharge	75 % (simple) / 90 % (avancé)
Puissance max de charge/décharge	$3\,\text{kW} \rightarrow 1{,}5\,\text{kWh}$ par demi-heure

TABLE 1 – *Paramètres du modèle de batterie résidentielle. Note : le rendement de 75 % s'applique à l'EMS simple ; le rendement de 90 % (charge et décharge séparés) s'applique à l'EMS avancé.*

Logique de l'EMS. L'EMS implémenté opère une logique à seuil déterministe, exécutée à chaque pas de temps de 30 minutes.

Cas 1 — surplus solaire (Net_Load < 0) : L'énergie excédentaire est dirigée en priorité vers la charge de la batterie, dans la limite de sa capacité restante et du rendement de charge. Tout surplus ne pouvant être stocké est exporté au réseau.

Listing 1 – EMS – cas surplus solaire

```
energy_to_store = -net_load * EFFICIENCY
charge = min(energy_to_store, SOC_MAX - current_soc)
new_soc = current_soc + charge
```

Cas 2 — déficit énergétique (Net_Load > 0) : La batterie se décharge pour couvrir le besoin, dans la limite de son énergie disponible au-dessus de $\text{SOC}_{\min}$. Le résidu non couvert est importé depuis le réseau.

Listing 2 – EMS – cas déficit énergétique

```
discharge = min(energy_needed, current_soc - SOC_MIN)
new_soc = current_soc - discharge
grid_needed = energy_needed - discharge
```

EMS avancé avec tarification dynamique. Une version enrichie de l'EMS intègre une structure tarifaire à deux niveaux inspirée des contrats heures pleines/heures creuses (Tableau 2). En priorisant la recharge batterie avec le surplus solaire, l'EMS se constitue une réserve pour éviter d'importer au tarif de pointe en soirée, représentant un gain de $0{,}32\,€$/kWh par rapport à l'alternative export-puis-rachat. Ce raisonnement économique est encodé directement dans la boucle de simulation via les variables `buy_price` et `sell_price`, calculées dynamiquement à chaque itération.

Période	Prix d'achat	Prix de vente
Heures de pointe (17h–21h)	0,40 €/kWh	—
Heures creuses	0,20 €/kWh	—
Injection réseau (fixe)	—	0,08 €/kWh

TABLE 2 – *Structure tarifaire de l'EMS avancé.*

2.4 Prévision de la consommation par apprentissage automatique

Deux approches de prévision ont été implémentées et confrontées. Le LSTM exploite nativement la structure séquentielle des données : en maintenant un état caché sur 48 pas de temps, il peut capturer des dépendances temporelles longues sans que celles-ci soient explicitement construites. En contrepartie, il requiert une normalisation stricte des entrées, un temps d'entraînement significatif, et reste peu interprétable. XGBoost, à l'inverse, opère sur des features tabulaires statiques — les dépendances temporelles doivent donc être encodées manuellement via des variables de lag. Ce surcoût en feature engineering est compensé par une convergence rapide, une meilleure interprétabilité et une robustesse supérieure sur des volumes de données modestes.

Modèle LSTM. Un réseau de neurones récurrents de type LSTM est entraîné pour prédire la consommation du pas de temps suivant à partir des 48 derniers pas (24 heures de contexte). Les variables d'entrée sont : la consommation (kWh), l'heure de la journée (`hour`) et le jour de la semaine (`day_of_week`). Les données sont normalisées via un `MinMaxScaler` entre 0 et 1. L'architecture retenue comprend une couche LSTM de 50 unités, un dropout de 20 % et une couche Dense de sortie. Un mécanisme d'*early stopping* (patience : 5 epochs) limite le surapprentissage. La séparation chronologique des données (70 % entraînement / 15 % validation / 15 % test) est strictement respectée.

Modèle XGBoost multi-horizon. Un modèle de gradient boosting est entraîné en parallèle, avec un feature engineering enrichi : aux variables temporelles s'ajoutent des lags (consommation à -30 min, -24 h et -7 jours) ainsi qu'une moyenne glissante sur 24 heures. L'approche multi-horizon est implémentée via 6 modèles indépendants, chacun entraîné pour un horizon différent ($+30$ min à $+3$ h). Cette stratégie *Direct Multi-Step Forecasting* évite l'accumulation d'erreurs inhérente aux approches itératives.

La comparaison des deux architectures révèle des différences structurelles importantes dans leur rapport au temps. Le LSTM apprend implicitement les dépendances temporelles à partir des séquences brutes, ce qui le rend théoriquement plus flexible mais aussi plus gourmand en données. XGBoost, lui, traite chaque pas de temps comme un vecteur de features indépendant : la « mémoire » du système est entièrement encodée dans les variables de lag. Cette approche est moins élégante sur le papier, mais elle s'avère plus robuste sur des séries courtes (deux ans de données pour un seul foyer) car elle bénéficie de la régularisation native de XGBoost (paramètres α, λ, profondeur max des arbres) et de sa convergence rapide par *early stopping*. L'analyse de l'importance des variables confirme la prédominance du lag à 30 minutes (`lag_1`) et du lag à 24 heures (`lag_48`), qui capturent respectivement l'inertie immédiate de la consommation et sa périodicité journalière. Les variables calendaires (`hour`, `day_of_week`) arrivent loin derrière, ce qui suggère que la consommation du client 13 est davantage pilotée par ses habitudes individuelles que par les patterns hebdomadaires généraux.

2.5 Architecture de la chaîne de traitement

L'implémentation Python repose sur une chaîne de traitement linéaire et reproductible. La Figure 3 en présente les grandes étapes.

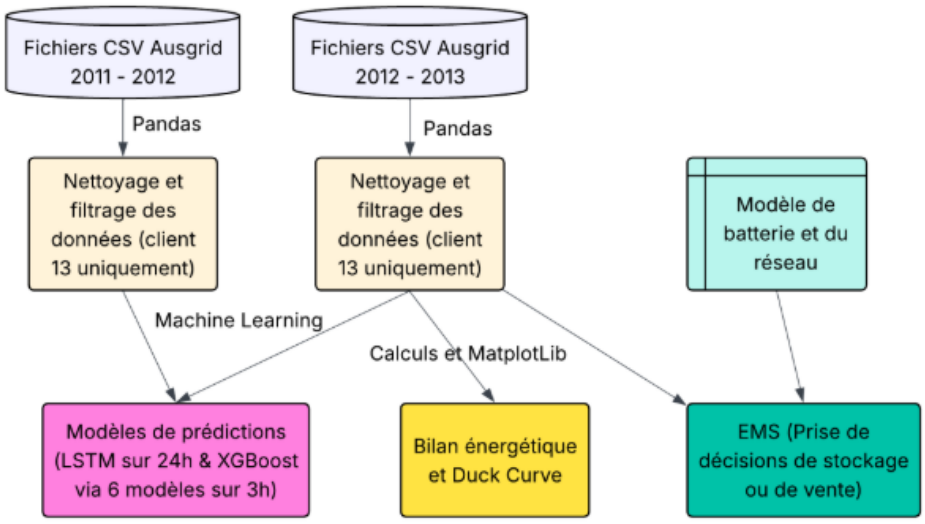


FIGURE 3 – *Architecture de la chaîne de traitement. Chaque étape produit des colonnes explicitement nommées dans le DataFrame* `df_final`*, référentiel commun de toutes les visualisations.*

3 Résultats

3.1 Bilan énergétique sans stockage

L'analyse du client 13 sans batterie révèle les résultats suivants pour l'année 2012–2013 : consommation totale de 4 287 kWh, production solaire de 2 910 kWh, importation réseau de 3 323 kWh, et taux d'autoconsommation de 33,1 %. La *Duck Curve* de la Figure 2 illustre la nature du problème : le surplus de midi n'est pas valorisé localement et le pic de consommation du soir est intégralement couvert par le réseau.

3.2 Impact de la batterie et de l'EMS

L'intégration de la batterie de 7 kWh avec l'EMS glouton (rendement 75 %) réduit l'importation réseau annuelle de 3 323 kWh à 1 999 kWh, soit **une réduction de 39,8 %**. La Figure 4 compare les importations annuelles avant et après l'ajout du système de stockage, et la Figure 5 détaille le comportement de la batterie sur la journée du 15 janvier 2013 : le SOC monte progressivement pendant le surplus solaire de la matinée, puis se décharge en soirée pour réduire les importations pendant les heures de pointe tarifaires.

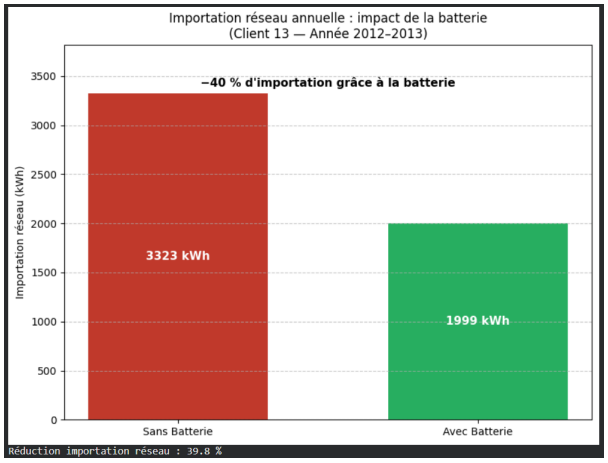


FIGURE 4 – *Importation réseau annuelle sans batterie (3 323 kWh) et avec une batterie de 7 kWh pilotée par l'EMS (1 999 kWh). Réduction : 39,8 %.*

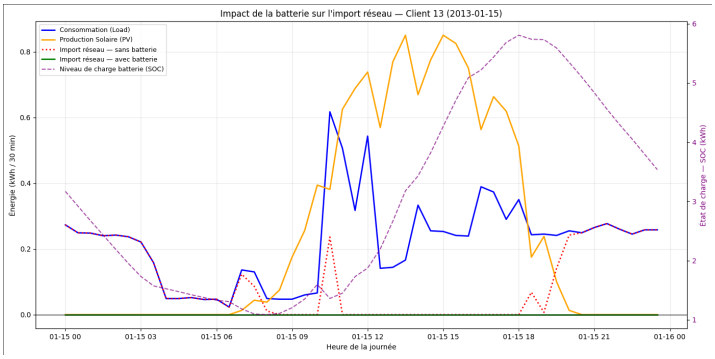


FIGURE 5 – *Impact de la batterie — client 13, 15 janvier 2013 (axe gauche : flux en kWh/30 min ; axe droit : SOC en kWh). La courbe verte est systématiquement inférieure à la courbe rouge en soirée.*

3.3 Analyse économique

L'EMS avancé avec tarification dynamique produit des résultats supérieurs à ceux de l'algorithme glouton simple. L'importation réseau annuelle tombe à 2 109 kWh (contre 1 999 kWh pour l'EMS simple, et 3 323 kWh sans batterie), soit une réduction de 36,5 % par rapport à la situation initiale. En parallèle, 448 kWh sont exportés vers le réseau sur l'année, générant un revenu de $448 \times 0{,}08 \approx 36$ €.

Le bilan financier annuel s'établit comme suit. Sans batterie, en supposant que 22 % des imports surviennent aux heures de pointe (17h–21h) et le reste en heures creuses, la facture d'import s'élève à environ 811 €/an. Avec l'EMS avancé, l'algorithme parvient à réduire à moins de 5 % la part des imports en heures de pointe, ramenant le coût d'import à environ 443 €/an. En déduisant les 36 € de revenu d'export, le coût net descend à 407 €/an. L'économie annuelle réalisée est donc de l'ordre de **404 €/an**.

Scénario	**Import annuel (kWh)**	**Coût net estimé (€/an)**
Sans batterie	3 323	811
EMS simple (75 %)	1 999	488
EMS avancé (90 %, tarif)	2 109	407

TABLE 3 – *Comparaison financière des trois scénarios (client 13, 2012–2013). Le coût net de l'EMS avancé intègre le revenu d'export de 36 €/an.*

Pour estimer le temps de retour sur investissement (TRI), le coût d'installation d'un système de batterie résidentielle de 7 kWh est typiquement compris entre 4 500 € et 6 000 € (fourniture et pose). En retenant une valeur centrale de 5 000 € et une économie annuelle de 404 €, le TRI s'établit à :

$$\text{TRI} = \frac{5\,000}{404} \approx 12{,}4 \text{ ans}$$

ce qui est compatible avec la durée de vie commerciale des batteries lithium-ion résidentielles (10–15 ans), en supposant des coûts et économies constants sur la période. Ces estimations sont toutefois sensibles aux

hypothèses tarifaires, à la dégradation de la capacité de la batterie dans le temps (typiquement $-2\,\%$ à $-3\,\%$ de capacité par an), et à l'évolution des prix de l'électricité. Un calcul actualisé conduirait à un TRI supérieur à 12,4 ans ; une analyse de sensibilité à ces paramètres constituerait une perspective d'amélioration du modèle.

3.4 Performances des modèles de prévision

Pour la prédiction à 30 minutes de la consommation GC, le modèle LSTM obtient une MAE de 0,179 kWh et une RMSE de 0,322 kWh. Le modèle XGBoost surpasse le LSTM avec une MAE de 0,118 kWh et une RMSE de 0,223 kWh. Les résultats sont synthétisés dans le Tableau 4. Le modèle XGBoost multi-horizon atteint une MAE moyenne de 0,202 kWh sur les 6 pas de temps (horizon de 3 h). L'analyse de l'importance des variables confirme la prédominance des lags récents (`lag_1`, `lag_48`) sur les variables calendaires, ce qui traduit la forte autocorrélation de la consommation résidentielle à court terme.

Modèle	**MAE (kWh)**	**RMSE (kWh)**
LSTM	0,179	0,322
XGBoost (+30 min)	0,118	0,223
XGBoost (moyenne sur 3 h)	0,202	—

TABLE 4 – *Performances comparées des modèles de prévision (client 13, jeu de test 2012–2013).*

4 Discussion

Les résultats confirment que l'intégration d'une batterie et d'un EMS déterministe suffit à réduire significativement la dépendance au réseau, sans recourir à des méthodes d'optimisation complexes. La logique gloutonne retenue est particulièrement pertinente pour un usage embarqué : sa faible empreinte computationnelle la rend déployable dans un boîtier résidentiel à faible coût.

La version enrichie de l'EMS, intégrant la tarification dynamique, ajoute une dimension économique à la décision de charge/décharge. La différence de $0{,}32\,€$/kWh entre le tarif de pointe et le tarif de rachat crée une incitation forte à stocker le surplus solaire plutôt qu'à l'injecter immédiatement, ce qui améliore à la fois le taux d'autoconsommation et la facture de l'utilisateur.

Sur le volet prédictif, la supériorité de XGBoost sur le LSTM s'explique principalement par la taille limitée du dataset disponible après filtrage (un seul foyer sur deux ans). Les architectures récurrentes bénéficient typiquement de volumes plus importants pour exprimer leur capacité de généralisation. En revanche, le feature engineering explicite de XGBoost (lags, moyenne glissante) exploite efficacement les régularités journalières et hebdomadaires bien présentes dans la consommation résidentielle.

Plusieurs limites méthodologiques méritent d'être soulignées. Premièrement, l'étude porte sur un unique foyer : les performances observées ne sont pas nécessairement représentatives de l'ensemble de la population de clients, même après filtrage. Deuxièmement, la logique gloutonne de l'EMS est myope — elle optimise chaque pas de temps de façon indépendante sans anticiper les conditions futures. Une approche par programmation dynamique ou par optimisation sous contraintes (MPC, *Model Predictive Control*) permettrait de mieux exploiter les prévisions météorologiques ou les pics de consommation prévisibles. Troisièmement, la structure tarifaire retenue est une simplification : les tarifs réels en Australie comportent des variations saisonnières et des plafonds journaliers qui affectent le calcul économique. Enfin, le modèle de

batterie ne tient pas compte de la dégradation progressive de la capacité au fil des cycles de charge et de décharge, qui peut atteindre 20 à 30 % sur la durée de vie du système.

Ces limites ouvrent des pistes concrètes pour la suite : couplage de l'EMS avec les prévisions XGBoost, extension à plusieurs foyers pour construire une logique de microgrid avec partage d'énergie, et intégration d'un modèle de vieillissement de batterie pour affiner l'analyse économique sur le long terme.

5 Conclusions

Ce projet a permis de concevoir, implémenter et évaluer une chaîne complète de gestion d'énergie pour un microgrid résidentiel photovoltaïque. L'EMS glouton réduit l'importation réseau de 39,8 %, et la version tarifaire améliore encore ce bilan sur le plan économique, avec une économie estimée à 404 €/an et un temps de retour sur investissement de l'ordre de 12 ans pour une batterie de 7 kWh. Le modèle XGBoost fournit des prévisions de consommation fiables (MAE = 0,118 kWh à 30 min), utiles pour une version anticipatrice de l'EMS.

Au-delà des performances individuelles, ce travail illustre la complémentarité entre les approches déterministes et les approches par apprentissage automatique dans le contexte de la gestion d'énergie. L'EMS à seuil est simple, rapide et embarquable ; le modèle XGBoost apporte la capacité d'anticipation nécessaire pour exploiter pleinement les tarifs variables et les prévisions de consommation. Leur couplage représente la prochaine étape naturelle de ce projet.

Les prochaines étapes porteront sur le couplage des deux briques — permettre à l'EMS d'utiliser les prévisions XGBoost pour anticiper les décisions de charge — ainsi que sur l'extension à un microgrid multi-foyers et des tests de sensibilité sur la capacité de la batterie (4 kWh, 7 kWh, 10 kWh).

Remerciements

Les auteurs remercient Mohamed Saâd El Harrab pour son encadrement tout au long du projet, ainsi que l'équipe du Co-Innovation Lab de l'ENPC.

Références

[1] International Energy Agency. *Renewables 2025 : Analysis and Forecasts to 2030*. Technical report, IEA, Paris, 2025. https ://www.iea.org/reports/renewables-2025. Licence : CC BY 4.0.

[2] E. L. Ratnam, S. R. Weller, C. M. Kellett et A. T. Murray. Residential load and rooftop pv generation : an Australian distribution network dataset. *International Journal of Sustainable Energy*, 2015. doi : 10.1080/14786451.2015.1100196.